Mecanismos de controle em Adaptive RAG e Self-RAG

DCA0305 · UFRN

Micarlos, Rodrigo e Werbert



Lacunas de evidência e controle

Uma recuperação pode encontrar um fato e omitir sua justificativa

Quando buscar mais e quando revisar a resposta?

- O contexto inicial pode ser suficiente, incompleto ou confundível.
- Uma passagem recuperada pode ser descartada antes da geração.
- Uma revisão pode corrigir um item ou introduzir um erro.

O estudo acompanha decisões, evidências e efeitos.

Variantes e foco da análise

Variante	Comportamento implementado
LLM puro	Gera sem documentos.
Baseline	Gera com o contexto inicial fornecido.
Adaptive	Planeja, seleciona evidência e busca lacunas antes de gerar.
Self-RAG	Gera um rascunho, verifica apoio/cobertura e revisa alvos.

Adaptive e Self-RAG são o objeto; as outras variantes são referências.

Corpus e ambiente local

5
PDFs em português

286
páginas físicas

679
fragmentos

Modelos e hardware

Qwen 2.5 3B, Q4_K_M
EmbeddingGemma 300M, BF16
Ollama em Apple M1, 8 GB

Recuperação e contexto

Híbrida: TF-IDF + embeddings
Fragmentos: 900 / 150 caracteres
Contexto: 6.500 caracteres

Perguntas sobre detalhes dos cinco TCCs. Janela de 4.096 tokens; saída máxima de 1.024 tokens.

Condição controlada de avaliação

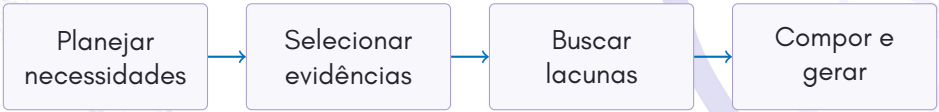
Cenário planejado	n	O que observar
Direto	5	Preservar evidência suficiente.
Duas etapas	5	Buscar informação complementar.
Distrator	5	Distinguir entidades, métricas e condições.
Não respondível	5	Recusar informação não apresentada.

Contextos iniciais construídos, iguais entre as variantes RAG.

20 perguntas × 4 variantes = 80 respostas. Semente 42 e temperatura zero.

Adaptive: busca antes da geração

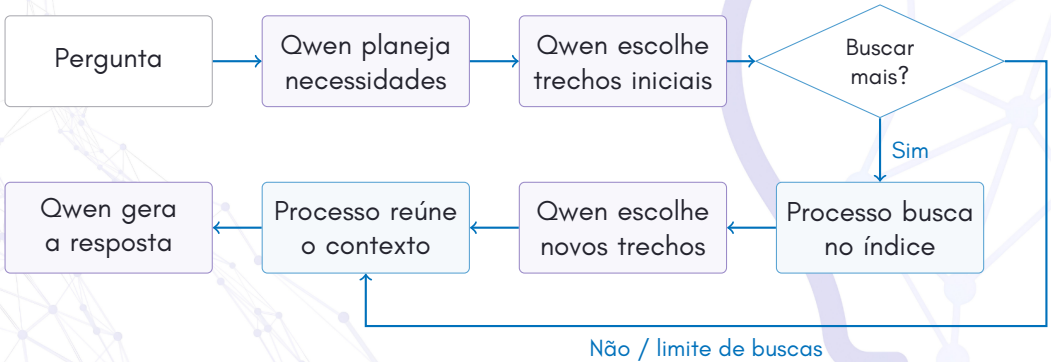
Até cinco necessidades; até três buscas complementares



- Necessidade parcial ou ausente motiva nova consulta.
- Evidências são reunidas por necessidade, dentro do orçamento.

Na condição controlada, investiga mesmo com rota single.

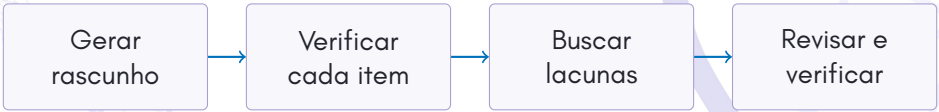
Adaptive: fluxo de execução



Seleção por necessidade; busca se falta evidência e há orçamento. Até três buscas extras.

Self-RAG: verificação e revisão

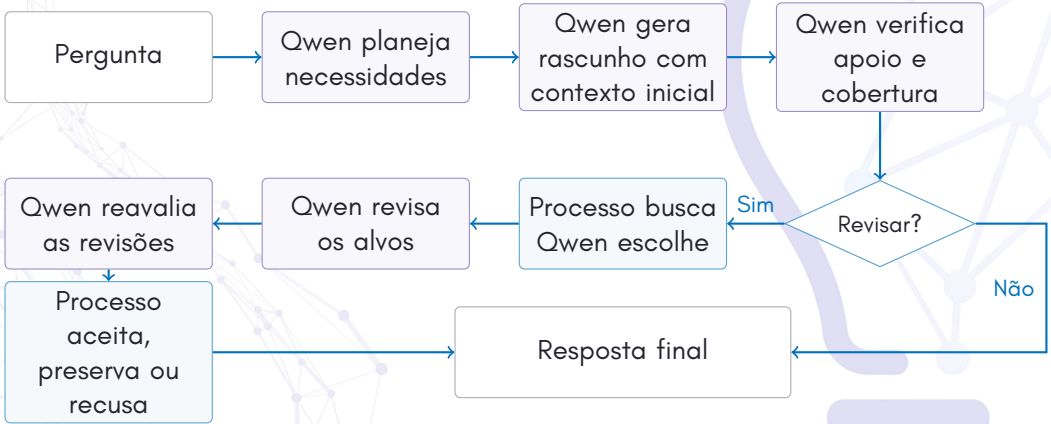
Um rascunho, seleção de alvos e uma etapa de revisão



- Apoio e cobertura são checados separadamente.
- Aceita revisão apoiada; preserva original sustentado ou recusa a parte.
- Uma falsa aprovação pode proteger um erro.

Guardas de citações e números são auxiliares. Uma etapa pode exigir várias chamadas LLM.

Self-RAG: fluxo de execução



Avaliação dos mecanismos

O que mudou entre a lacuna e a resposta final?

Lacuna → decisão → busca

Entrega → revisão → efeito

- 40 cadeias de controle e 80 respostas finais.
- Recuperação, entrega e qualidade final são medidas distintas.
- Benefício sobre o próprio rascunho é separado de vitória sobre o baseline.

A seleção perde parte do ganho da busca

Contagens por pergunta nas 20 questões de cada política

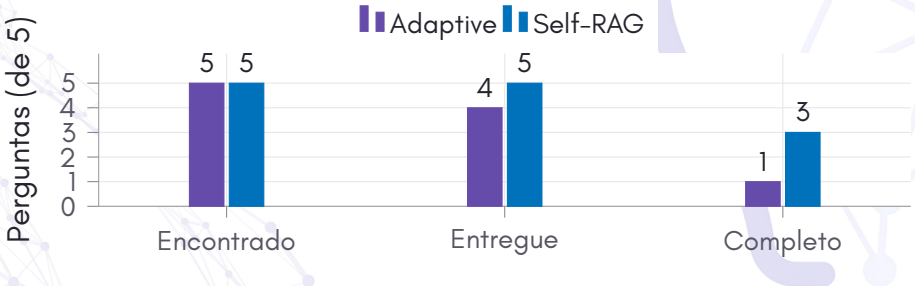
Perguntas com	Adaptive	Self-RAG
Busca extra	19/20	17/20
Complemento relevante encontrado	10/20	10/20
Algum complemento entregue	5/20	6/20

Encontrar evidência não garante entregá-la ao gerador.

Critérios com complemento: 13 recuperados em cada política; 5 e 7 entregues.

Evidência nas perguntas de duas etapas

Cinco perguntas; algum complemento e contexto completo são distintos



Contexto completo não implica resposta integralmente correta.

Q02: busca complementar e correção

No projeto da Biblioteca (DOC01), como o Gspread autentica o acesso à planilha e por que a Google Drive API precisou ser ativada junto à Google Sheets API?

Etapa	Contexto e resposta do Self-RAG
Contexto inicial	Conta de serviço e chave JSON, sem o motivo da Drive API.
Rascunho	Atribui à Drive API o compartilhamento da planilha.
Busca e revisão	Busca a página 26 e corrige: localizar a planilha pelo nome.

Correção parcial: autenticação incompleta. Adaptive encontra a página, mas perde o motivo na seleção.

Q18: evidência correta, erro preservado

Gargalos de single e proposta para reduzir ociosidade

Evidência entregue	Efeito na resposta
Ambos recebem a proposta de usar **tasking do OpenMP**.	Adaptive menciona tasking e erra uma descrição. Self-RAG melhora swap, mas mantém uma estratégia falsa.

A falsa aprovação inicial pode bloquear parte do reparo.

DOC05, página física 47. Benefício misto: evidência disponível e erro remanescente.

Abstenção e correção da resposta

Variante	Recusa total	Acerto integral
LLM puro	3/5	2/5
Baseline	5/5	3/5
Adaptive	3/5	1/5
Self-RAG	4/5	2/5

Recusa total não é sinônimo de resposta correta.

Cinco perguntas não respondíveis. Acerto integral exige recusa e justificativa completa conforme os critérios.

Q04: revisão de uma recusa correta

No sistema da Biblioteca Padre Jaime Diniz (DOC01), qual foi a latência mediana de consulta ao dashboard, em milissegundos, medida em um teste de desempenho?

Etapa	Observação
Contexto inicial	TTL de 120 segundos, sem medição de latência.
Resposta inicial	Baseline e rascunho recusam informar o valor.
Busca e seleção	Destacam o TTL do cache.
Revisão Self-RAG	Informa 120 como latência e recebe aprovação.

TTL mede a validade do cache. Houve regressão; Adaptive também confunde TTL e latência.

Custo observado e qualidade final

Variante	Chamadas	Tempo (s)	Acerto	Critérios
LLM puro	1,00	5,12	2/20	12,5%
Baseline	1,00	13,04	8/20	55,0%
Adaptive	7,05	70,19	4/20	35,8%
Self-RAG	20,40	159,84	7/20	56,7%

Maior esforço não garante melhor resposta completa.

Médias por resposta concluída. Critérios: fração média plenamente atendida. Custos Self-RAG misturam revisão em lote e por item.

Limites da comparação

- Uma semente; perguntas vistas no desenvolvimento.
- Contexto inicial construído; há falhas na caracterização de cenários.
- Self-RAG combina revisão conjunta e por item durante a coleta.

As médias descrevem a coleta; não isolam uma política uniforme.

Sem ablação, recuperação natural avaliada ou comparação com outro modelo/API.

Conclusão

- As buscas localizam complementos ausentes no contexto inicial.
- Seleção e crítica podem perder o benefício ou preservar um erro.
- O Self-RAG corrige aspectos do rascunho, com efeitos mistos e regressão.

Benefícios condicionais, com custo adicional e sem superioridade geral.

Próxima avaliação: revisão uniforme, anotação humana e perguntas independentes com recuperação natural.

Referências

- Lewis et al. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*.
  arxiv.org/abs/2005.11401
- Jeong et al. (2024). *Adaptive-RAG*. NAACL.
  aclanthology.org/2024.naacl-long.389
- Asai et al. (2024). *Self-RAG*. ICLR.
  openreview.net/forum?id=hSyW5go0v8

Apoio: as 111 verificações do Self-RAG

Classificação	Ocorrências
Aprovação de afirmação sustentada	25
Sinalização adequada de falta de apoio/contradição	30
Aprovação indevida	10
Falta de aprovação de afirmação sustentada	16
Indeterminado ou metarresposta	28
Apoio literal com artefato de extração	2

Apoio e cobertura separados; verificações dependentes. Não são 111 perguntas.

Apoio: abstenção e itens extras

Variante	Flag: algum item	Recusa ao pedido
LLM puro	9	9
Baseline	8	8
Adaptive	10	7
Self-RAG	13	8

Q13: responde terminate, mas recusa um requisito extra.

20 perguntas por variante. Recusa ao pedido inclui total e parcial; itens extras podem inflar a flag geral.