Busca adaptativa e autoverificação em RAG: Análise dos mecanismos de controle

Francisco Micarlos Teixeira Pinto
Departamento de Computação e Automação (DCA)
Universidade Federal do Rio Grande do Norte (UFRN)
Natal, RN, Brasil
micarlos.teixeira.123@ufrn.edu.br

Rodrigo de Menezes Souza
Departamento de Computação e Automação (DCA)
Universidade Federal do Rio Grande do Norte (UFRN)
Natal, RN, Brasil
rodrigo.menezes.121@@ufrn.edu.br

Werbert Arles de Sousa Barradas
Departamento de Computação e Automação (DCA)
Universidade Federal do Rio Grande do Norte (UFRN)
Natal, RN, Brasil
werbert.barradas.390@ufrn.edu.br

***Resumo*—Este trabalho analisa mecanismos de busca adaptativa e verificação/revisão em duas políticas: Adaptive-RAG e Self-RAG. Utilizam-se Qwen 2.5 3B local, cinco documentos em português e 20 perguntas, com contextos iniciais comuns às variantes RAG. A avaliação examina 40 cadeias de controle e 80 respostas, distinguindo evidência recuperada, evidência entregue, revisão e custo. Nas cinco perguntas de duas etapas, ambas as políticas encontram complementos relevantes; algum complemento chega ao gerador em quatro casos no Adaptive e cinco no Self-RAG, enquanto contexto suficiente para todos os critérios chega em um e três casos. O Self-RAG apresenta benefício local sobre o próprio rascunho em nove perguntas, cinco com efeitos mistos, e uma regressão. Os resultados mostram benefícios condicionais, perdas na seleção e falsas aprovações, sem superioridade geral na qualidade final. O tamanho da amostra e as condições controladas delimitam o alcance dos resultados.**

***Palavras chave*—recuperação aumentada por geração, Adaptive-RAG, Self-RAG, verificação de respostas, controle de recuperação.**

I. Introdução

A recuperação aumentada por geração (RAG) combina conhecimento paramétrico com evidências de uma coleção externa [1]. Uma recuperação única pode fornecer um fato e omitir sua justificativa; mesmo com a informação presente, seleção e geração podem descartá-la ou interpretá-la incorretamente. Isso motiva mecanismos que decidem como buscar e verificam a resposta.

Este estudo investiga *quando busca adaptativa e verificação tratam lacunas do contexto inicial, onde falham e quanto esforço acrescentam*. O foco são duas políticas denominadas Adaptive e Self-RAG. Baseline e LLM puro fornecem referências; cinco documentos constituem o corpus de teste. A contribuição é uma análise instrumentada que separa localizar evidência, entregá-la ao gerador e alterar a resposta, identificando benefícios e regressões nos rastros.

II. Fundamentação teórica

Adaptive-RAG seleciona entre geração sem recuperação, recuperação única e iterativa conforme a complexidade da pergunta, usando um classificador treinado [2]. Self-RAG treina um modelo para recuperar sob demanda e produzir tokens de reflexão sobre recuperação e crítica [3]. As políticas deste trabalho são adaptações por prompts: não houve treinamento desses mecanismos originais.

A distinção é entre apoio factual e cobertura: uma resposta pode conter fatos sustentados e omitir parte do pedido. Analogamente, recuperar uma passagem não garante sua seleção, e entregá-la não garante interpretação correta. Uma revisão pode completar um aspecto e introduzir outro erro.

III. Metodologia

A. Corpus, modelos e condição avaliada

O corpus reúne cinco TCCs do curso de Engenharia da Computação da UFRN: sistema de doações com Streamlit (DOC01), rastreamento solar (DOC02), gestão de rotinas multiagente (DOC03), modelos de linguagem-visão para interfaces (DOC04) e migração reversa no tempo (DOC05) [4]–[8]. Os PDFs somam 286 páginas físicas, 269 com texto extraído. A extração por *pypdf* produz 679 fragmentos de até 900 caracteres e sobreposição de 150, sem cruzar páginas ou documentos. Fontes, hashes e identificadores permitem rastrear as passagens.

Geração e controle usam `qwen2.5:3b`, quantizado em Q4_K_M, via Ollama em Apple M1 com 8 GB [9], [10]. A recuperação combina TF-IDF com n-gramas de três a cinco caracteres e EmbeddingGemma 300M BF16 [11], fundidos por RRF [12], com constante 60, conjunto candidato de 20 e quatro âncoras por busca. Há expansão de vizinhos e restrição ao documento solicitado. O contexto é limitado a 6.500 caracteres; a janela do LLM, a 4.096 tokens; a saída de geração, a 1.024 tokens.

São 20 perguntas, quatro por documento: cinco diretas, cinco de duas etapas, cinco com distratores e cinco não respondíveis. Na condição controlada, baseline, Adaptive e Self-RAG recebem o mesmo pacote inicial construído; buscas extras consultam o corpus comum. O LLM puro recebe apenas a pergunta. Gabaritos, rubricas, cenários e páginas esperadas não entram nos prompts. A execução utiliza semente 42 e temperatura zero, totalizando 80 respostas. A recuperação inicial natural não é avaliada.

B. Políticas Adaptive e Self-RAG

O Adaptive planeja até cinco necessidades e consultas. Um seletor examina unidades textuais existentes e classifica a evidência como encontrada, parcial ou ausente. Necessidades não atendidas motivam buscas adicionais, limitadas a três por execução e sem repetir consultas textualmente equivalentes. As

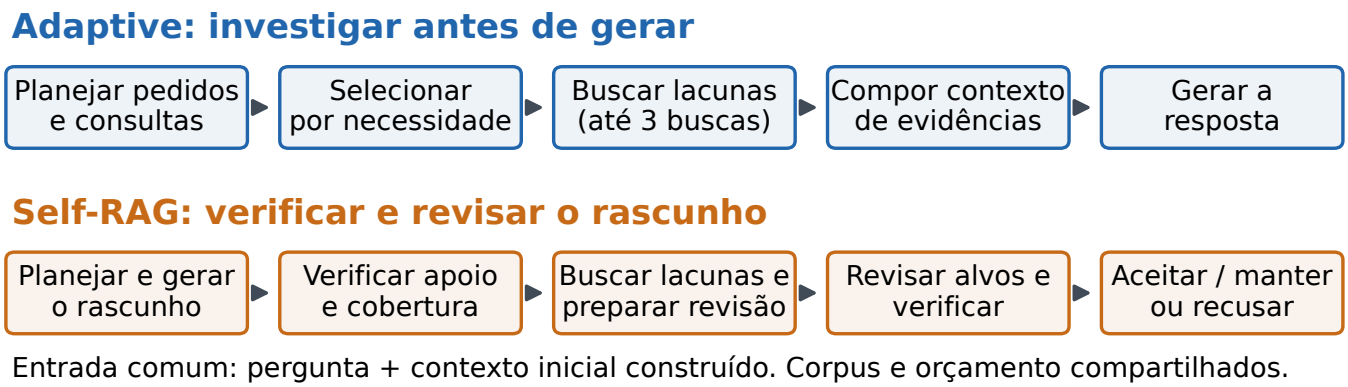


Figura 1. Políticas na condição controlada, com até três buscas extras por execução. Adaptive investiga antes de gerar; Self-RAG verifica e revisa alvos, preservando itens aprovados.

passagens escolhidas são reunidas por necessidade, empacotadas em rodízio e entregues ao gerador. Seleção inteiramente vazia aciona o pacote inicial como alternativa; uma seleção não vazia ainda pode descartar a evidência final. No modo controlado, a investigação ocorre mesmo com rota *single*; assim, não se mede economia decorrente do roteamento.

O Self-RAG planeja e gera um rascunho, organiza evidências e verifica apoio e cobertura por item. Apoio é classificado como sustentado, contradito ou incerto; cobertura, como completa ou parcial. Itens reprovados ou incompletos motivam busca e revisão dentro do mesmo escopo. Fontes de itens julgados sustentados ficam protegidas; candidatos são verificados quanto a apoio e preservação. Uma revisão apoiada pode ser aceita; caso contrário, mantém-se um original sustentado ou recusa-se a parte sem apoio. Guardas de citações e números são auxiliares e falíveis. A Figura 1 resume as trajetórias.

C. Procedimento de avaliação

A avaliação abrange 20 perguntas, 40 cadeias de controle e 80 respostas. As respostas e as decisões de controle são examinadas a partir de critérios de correção e evidências conferidos nas fontes. Os critérios consideram o pedido original, sem incorporar requisitos adicionais criados pelo planejador.

Anotam-se suficiência inicial, complemento recuperado, complemento entregue, efeito sobre a resposta e custo. *Contexto completo* exige evidência para todos os critérios; não significa resposta correta. Benefício do Self-RAG frente ao próprio rascunho é separado de vantagem sobre o baseline. Acerto integral exige todos os critérios atendidos e ausência de erro material; cobertura média dá peso igual às perguntas e não conta critérios parciais como completos.

Chamadas de planejamento, seleção, crítica, preservação e geração entram no custo. A latência corresponde ao processamento de cada resposta concluída, excluindo preparação e aquecimento. No baseline, o pacote inicial é fornecido, portanto suas buscas extras são zero. A análise é descritiva; decisões sucessivas sobre uma mesma pergunta não são tratadas como observações independentes.

Tabela I
RECUPERAÇÃO E ENTREGA DE EVIDÊNCIA NAS 20 PERGUNTAS POR POLÍTICA.

Perguntas com	Adaptive	Self-RAG
Busca extra	19	17
Complemento relevante encontrado	10	10
Algum complemento entregue	5	6

IV. RESULTADOS E DISCUSSÃO

A. Recuperação e entrega de evidência

Nas 20 perguntas por política, Adaptive busca complementos em 19 e Self-RAG em 17. Ambos encontram informação nova relevante em dez perguntas, mas a entregam ao gerador em cinco e seis, respectivamente (Tabela I). Nos critérios individuais, há 13 complementos recuperados em cada política, com cinco entregues no Adaptive e sete no Self-RAG. O ganho da busca pode, portanto, perder-se na seleção.

Nas cinco perguntas de duas etapas, ambas encontram algum complemento; o Adaptive o entrega em 4/5 e o Self-RAG em 5/5. Contexto suficiente para todos os critérios chega em apenas 1/5 e 3/5 (Figura 2). Esses são resultados sobre evidência, não acertos finais. Nos distratores, ambas recuperam complementos em duas perguntas, mas não os entregam (Tabela II). Em Q11, a causa correta de uma falha é encontrada e descartada; em Q14, dados do OSWorld não chegam ao gerador, enquanto o cabeçalho ScreenSpot entregue ainda é interpretado incorretamente.

B. Verificação e revisão

O Self-RAG apresenta benefício local sobre o próprio rascunho em nove perguntas, cinco com efeitos mistos, e regressão em uma; nas dez restantes, não se identifica benefício local. Esses ganhos são relativos à resposta inicial do próprio Self-RAG; a comparação com o baseline é apresentada na Tabela III. A verificação detecta lacunas e afirmações sem apoio, mas também aprova erros e solicita revisões desnecessárias. Além

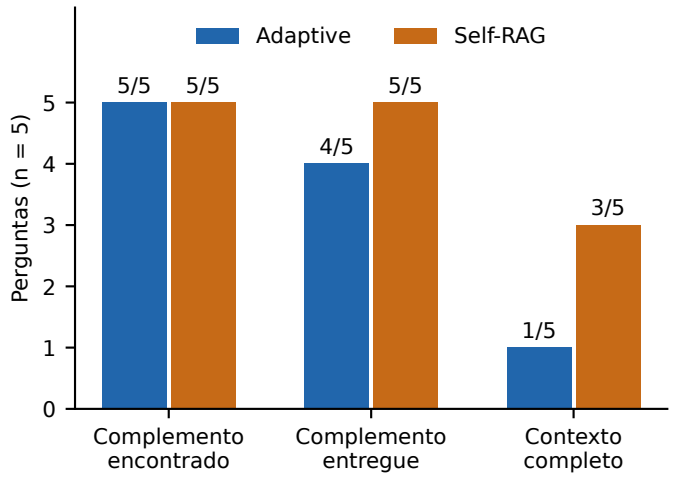


Figura 2. Encontrar, entregar algum complemento e entregar contexto completo nas cinco perguntas de duas etapas. A suficiência do contexto é avaliada separadamente da correção da resposta final.

Tabela II
COMPLEMENTO ENCONTRADO (R) E ENTREGUE (E), POR CENÁRIO.

	Adaptive		Self-RAG	
Cenário (5 perguntas)	R	E	R	E
Direto	1	1	1	1
Duas etapas	5	4	5	5
Distrator	2	0	2	0
Não respondível	2	0	2	0

Contam-se perguntas com algum complemento útil, inclusive limitações que justificam recusa.

disso, uma afirmação sustentada pode estar incompleta: verificar apoio factual e verificar cobertura são tarefas complementares.

1) Q02: complementação e correção: O pedido envolve autenticação Gspread e o motivo da Drive API. O rascunho Self-RAG atribui à API o compartilhamento da planilha. O crítico detecta falta de apoio, a busca encontra a página física 26 do DOC01 [4] e a revisão explica a localização pelo nome antes do acesso pela Sheets API. A autenticação permanece incompleta, e outro candidato incorreto também é aprovado. O Adaptive recupera a mesma página, mas não a seleciona para o motivo solicitado.

2) Q18: evidência entregue e erro protegido: Ambos entregam a proposta de *tasking* do DOC05 [8]. O Adaptive a menciona, mas erra uma descrição de *single*. O Self-RAG melhora a explicação do *swap*, porém preserva uma estratégia falsa já aprovada. A informação correta disponível não corrige todos os itens: a proteção pode conservar erro quando a crítica inicial falha.

3) Q04: revisão prejudicial: Baseline e rascunho Self-RAG recusam informar uma latência não medida no DOC01. A crítica reprova a recusa e desencadeia busca/revisão. O TTL do cache, de 120 segundos [4], vira resposta 120 ao pedido em milissegundos e recebe aprovação. Há regressão frente ao rascunho e ao baseline, com confusão de grandeza e unidade. O Adaptive também comete essa confusão.

O planejamento acrescenta requisitos não solicitados em oito perguntas e necessidades redundantes em seis. Em Q15, omite a causalidade pedida; em Q13, recusa um requisito adicional apesar de responder ao pedido original. Assim, a ocorrência de recusa deve ser interpretada em relação à pergunta, pois pode se referir a um item que nem sequer foi solicitado.

C. Custo e qualidade final

A Tabela III reúne custo observado e qualidade complementar. Adaptive e Self-RAG fazem números próximos de buscas extras, mas o segundo acrescenta verificação e revisão, elevando chamadas e latência. O baseline recebe o contexto pronto; seus tempos não incluem a recuperação inicial natural. Os resultados de custo são descritivos e correspondem às condições avaliadas.

O Self-RAG atende plenamente, em média, 56,7% dos critérios, próximo aos 55,0% do baseline, mas obtém menos acertos integrais: sete contra oito. O Adaptive obtém quatro. Os controles mostram intervenções úteis em casos identificáveis, sem superioridade geral na resposta final. Falhas de seleção, interpretação e crítica explicam por que localizar evidências e aumentar esforço não garantem melhor resposta.

V. LIMITAÇÕES

Os contextos iniciais foram construídos para observar os mecanismos de controle; os resultados não representam diretamente o desempenho com recuperação inicial natural. A suficiência da evidência varia entre perguntas de um mesmo cenário, e a extração dos PDFs pode alterar identificadores e a estrutura de tabelas. As médias do Self-RAG agregam revisões conjuntas e por item, sem isolar o efeito de cada forma de revisão.

Não foram realizadas ablações para separar planejamento, seleção e crítica, nem comparações controladas com outros modelos, equipamentos ou APIs. Assim, as diferenças de qualidade e latência descrevem o conjunto avaliado, sem atribuição causal a um componente isolado.

VI. CONCLUSÃO

O principal ganho observado foi a capacidade dos mecanismos de controle de recuperar evidências relevantes ausentes do contexto inicial utilizado pelo baseline. Adaptive e Self-RAG encontraram esses complementos em dez das 20 perguntas por política, entregando-os ao gerador em cinco e seis casos, respectivamente. No cenário avaliado, identificar lacunas e direcionar buscas adicionais permitiu ampliar a informação disponível para responder às perguntas. Esse benefício de recuperação constitui um resultado do controle, mesmo quando não se converte em acerto integral.

A contribuição do estudo é distinguir evidência localizada, entregue e usada, relacionando essas etapas às decisões e ao custo dos mecanismos. Parte dos complementos encontrados perde-se na seleção, e a verificação pode aprovar interpretações incorretas. O Self-RAG corrige aspectos do próprio rascunho, mas também pode introduzir regressões. Assim, os resultados sustentam benefícios condicionais de busca frente ao baseline

Tabela III
CUSTO E QUALIDADE FINAL POR VARIANTE ($n = 20$).

Variante	Chamadas LLM	Buscas extras	Latência média (s)	Acerto integral	Critérios atendidos
LLM puro	1,00	0,00	5,12	2/20	12,5%
Baseline	1,00	0,00	13,04	8/20	55,0%
Adaptive	7,05	1,90	70,19	4/20	35,8%
Self-RAG	20,40	1,85	159,84	7/20	56,7%

Médias por resposta concluída, com contexto inicial fornecido; sem preparação e aquecimento. Última coluna: fração média de critérios plenamente atendidos por pergunta.

com contexto fixo, sem demonstrar superioridade geral na qualidade final. A efetividade do controle depende tanto de encontrar novas evidências quanto de preservá-las e utilizá-las corretamente.

REFERÊNCIAS

[1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. tau Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 9459–9474. [Online]. Available: https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html

[2] S. Jeong, J. Baek, S. Cho, S. J. Hwang, and J. Park, "Adaptive-RAG: Learning to adapt retrieval-augmented large language models through question complexity," in *Proceedings of NAACL-HLT (Volume 1: Long Papers)*. Association for Computational Linguistics, 2024, pp. 7036–7050. [Online]. Available: https://aclanthology.org/2024.naacl-long.389/

[3] A. Asai, Z. Wu, Y. Wang, A. Sil, and H. Hajishirzi, "Self-RAG: Learning to retrieve, generate, and critique through self-reflection," in *International Conference on Learning Representations*, 2024. [Online]. Available: https://openreview.net/forum?id=hSyW5go0v8

[4] G. de Oliveira Barreto, "Desenvolvimento de um sistema interativo para monitoramento e análise do fluxo de materiais doados na biblioteca padre jaime diniz utilizando python e streamlit," Trabalho de Conclusão de Curso (Engenharia de Computação), Universidade Federal do Rio Grande do Norte, Natal, 2026. [Online]. Available: https://repositorio.ufrn.br/handle/123456789/69887

[5] A. C. G. Dias, "Sistema de rastreamento solar de dois eixos baseado em arduino aplicado a um protótipo de forno solar artesanal," Trabalho de Conclusão de Curso (Engenharia de Computação), Universidade Federal do Rio Grande do Norte, Natal, 2026. [Online]. Available: https://repositorio.ufrn.br/handle/123456789/69978

[6] Q. M. N. Ferraz, "Sistema assistivo multiagente para gestão de rotinas: Uma abordagem voltada a pessoas com TDAH," Trabalho de Conclusão de Curso (Engenharia de Computação), Universidade Federal do Rio Grande do Norte, Natal, 2026. [Online]. Available: https://repositorio.ufrn.br/handle/123456789/69972

[7] T. F. P. de Medeiros Rodrigues, "Navegação autônoma local: Estudo empírico sobre o ajuste de modelos de linguagem-visão compactos para o uso de interfaces gráficas," Trabalho de Conclusão de Curso (Engenharia de Computação), Universidade Federal do Rio Grande do Norte, Natal, 2026. [Online]. Available: https://repositorio.ufrn.br/handle/123456789/69002

[8] J. A. S. dos Santos, "Análise de escalabilidade de um algoritmo de migração reversa no tempo," Trabalho de Conclusão de Curso (Engenharia de Computação), Universidade Federal do Rio Grande do Norte, Natal, 2026. [Online]. Available: https://repositorio.ufrn.br/handle/123456789/70962

[9] Qwen Team, "Qwen2.5 technical report," arXiv:2412.15115, 2024. [Online]. Available: https://arxiv.org/abs/2412.15115

[10] Ollama, "qwen2.5:3b: Model library," Catálogo de modelos, acesso em: 18 out. 2026. [Online]. Available: https://ollama.com/library/qwen2.5:3b

[11] Google DeepMind, "EmbeddingGemma 300m: Model card," 2025, acesso em: 18 out. 2026. [Online]. Available: https://huggingface.co/google/embeddinggemma-300m

[12] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, "Reciprocal rank fusion outperforms condorcet and individual rank learning methods," in *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. ACM, 2009, pp. 758–759. [Online]. Available: https://cormack.uwaterloo.ca/cormacksigir09-rrf.pdf